

생성형 AI 합성 영상 데이터를 활용한 보행자 객체 검출 성능 개선

김태완*, 김준형*, 변승훈*, 이성환*, 최지호[○]

*한국전자기술연구원,

[○]한국전자기술연구원

e-mail: {kimtaewan21, kjun627, bshbsh72, qexd245}@keti.re.kr*, choijh1027@keti.re.kr[○]

Improving Pedestrian Object Detection Using Generative-AI Synthetic Video Data

Taewan Kim*, Jun-Hyeong Kim*, Seunghoon Byun*, Seong-Hwan Lee*, Jiho Choi[○]

*Korea Electronics Technology Institute,

[○]Korea Electronics Technology Institute

● 요약 ●

대시캠 기반 보행자(특히 교통사고 피해자) 검출은 실세계 사고 영상의 수집이 어려워 학습 데이터가 만성적으로 부족하다. 본 논문은 생성형 AI(text-to-video)로 생성한 합성 주행 영상을 실데이터에 보강하여 보행자 검출 성능을 개선하는 방안을 제안한다. 저품질 실영상을 제외한 실데이터 37클립(원본 5,550프레임)과, 생성형 AI로 제작 후 멀티모달 LLM(Gemini)으로 자동 라벨링한 합성 100클립(30,100프레임)을 구축하였다. YOLO11l/YOLO11x를 대상으로 실데이터 단독(A) 대 실데이터+합성데이터 1:1 혼합(B) 조건을 비교한 결과, 표준 해상도(960px)에서 합성데이터 보강이 두 모델 모두에서 mAP50-95를 개선하였으며(YOLO11l +1.3%p, YOLO11x +3.7%p), 입력 해상도와 합성데이터 효과 사이의 상호작용을 함께 분석하였다. 최종적으로 mAP50-95 0.5218을 달성하였다.

키워드: 생성형 AI(Generative AI), 합성 데이터(Synthetic Data), 객체 검출(Object Detection), YOLO, 데이터 증강(Data Augmentation), 보행자 검출(Pedestrian Detection)

I. Introduction

고령 보행자 및 교통사고 피해자를 대시캠(dashboard camera) 영상에서 실시간으로 검출하는 기술은 사고 예방 및 신속 대응을 위한 핵심 요소이다. 그러나 사고 장면은 본질적으로 희귀하고, 실제 사고 영상의 수집은 윤리적·법적 제약이 크기 때문에 딥러닝 기반 검출 모델 학습에 필요한 데이터가 만성적으로 부족하다. 데이터 부족은 소량 데이터에 대한 과적합(overfitting)을 유발하여 검출 정확도를 제한한다.

최근 text-to-video 생성형 AI는 사용자가 기술한 시나리오(예: 날씨, 환경, 사고 여부)에 따라 사실적인 주행 영상을 대량 생성할 수 있는 수준에 도달하였다 [3]. 합성 데이터를 학습에 활용하여 실데이터 부족을 보완하는 접근은 여러 비전 과제에서 효과가 보고되어 왔다 [4]. 이는 수집이 어려운 사고 상황 데이터를 저비용·대량으로 확보할 수 있는 새로운 경로를 제시한다. 본 논문은 생성형 AI로 제작한 합성 주행 영상을 실데이터에 보강하여 보행자 검출 모델의 성능을 개선하는 방안을 제안하고, 그 효과와 적용 조건을 실험적으로

검증한다.

본 논문의 기여는 다음과 같다. (1) 생성형 AI 영상 생성과 멀티모달 LLM 자동 라벨링을 결합한 합성 검출 데이터 구축 파이프라인을 제시한다. (2) 실데이터 단독 대비 합성데이터 보강의 성능 개선 효과를 정량적으로 측정한다. (3) 입력 해상도와 합성데이터 효과 간의 상호작용을 분석하여 합성데이터 활용의 실무적 가이드를 제공한다.

II. Preliminaries

1. Related works

YOLO(You Only Look Once) 계열은 경계상자와 클래스를 동시에 회귀하는 단일 단계(single-stage) 검출기로 실시간성이 우수하며 [3], 본 연구는 최신 버전인 YOLO11 [4]을 사용한다. 한편 실데이터

부족을 보완하기 위해 합성 데이터를 학습에 활용하는 연구가 여러 비전 과제에서 효과를 보고해 왔다 [2]. 최근 text-to-video 생성형 AI는 자연어 프롬프트로부터 시간적으로 일관된 사실적 영상을 합성할 수 있어 [1], 수집이 어려운 사고 영상을 대량 확보하는 수단으로 주목받는다. 생성 영상은 라벨이 없으므로 멀티모달 LLM(Gemini [5])을 활용해 경계상자를 자동 생성할 수 있다. 본 논문은 이들 기법을 결합한 합성 데이터 구축 파이프라인으로 보행자 검출 성능 개선을 검증한다는 점에서 기존 연구와 차별된다.

III. The Proposed Scheme

A. 데이터 구축.

실데이터는 저품질 32클립을 제외한 뒤 클립 단위로 분할하여 누수(leakage)를 방지하였다. 합성데이터는 생성형 AI로 제작한 영상을 프레임 추출 후 Gemini(gemini-3.5-flash, Vertex AI)로 자동 라벨링하여 구축하였다. 단일 클래스(person) 검출 문제로 정의하였다.

Table 1. 구축한 데이터셋 (클립 / 프레임)

구분	클립	프레임	구성
실-학습(train)	23	3,450	원본 100%
실-검증(val)	8	1,200	원본 100%
실-평가(test)	6	900	원본 100%
합성(generated)	100	30,100	합성 100%
혼합(mix, B조건)	-	6,850	원본 1:합성 1

검증(val)과 평가(test)는 전 구간 실데이터만 사용하여, 합성데이터가 평가에 개입하지 않도록 하였다.




Fig. 1. 원본 무단□단 데이터



Fig. 2. 생성□ AI로 만든 무단□단 데이터

B. 실험 설계.

두 모델(YOLO11l, 11x)에 대해 두 조건을 비교한다. 조건 A는 실데이터(train23)만, 조건 B는 실데이터에 합성데이터를 프레임 수 기준 1:1로 균형 혼합한다. 학습 레시퍼는 SGD(lr0=0.001), mosaic=0, warmup=0, 100 epoch, early stopping(patience=20), seed=0으로 고정하였다(과적합 억제). 입력 해상도 960px와 1280px를 비교하고, 평가 시 다중 스케일·반전 예측을 앙상블하는 TTA(Test-Time Augmentation) 적용 여부를 함께 측정하였다. 모든 모델은 실-평가셋(test6)에서 mAP50 및 mAP50-95로 평가하였다. 단, 1280px 고해상도 실험은 960px에서 모든 조건에 걸쳐 우수했던 11l에 한정하였다. 실험 환경은 RTX 5090(32GB), ultralytics 8.4.54이다.

C. 실험 결과.

Table 2는 960px에서의 결과이다. 학습하지 않은 zero-shot 대비 학습 모델의 성능이 크게 향상되며, 합성데이터 보강(B)이 두 모델 모두에서 mAP50-95를 개선하였다. 개선폭은 YOLO11l에서 +1.3%p(0.4455→0.4581), YOLO11x에서 +3.7%p(0.4035→0.4404)로, 과적합에 취약한 대형 모델(11x)에서 합성데이터의 효과가 더 크게 나타났다.

Table 2. 960px 검출 성능 (실-평가셋, mAP)

모델	조건	mAP50	mAP50-95
zero-shot (yolo11x)	-	0.6141	0.3775
YOLO11l	A: real	0.6520	0.4455
YOLO11l	B: real+gen	0.6607 (+0.0087)	0.4581 (+0.0126)
YOLO11x	A: real	0.6094	0.4035
YOLO11x	B: real+gen	0.6122 (+0.0028)	0.4404 (+0.0369)

괄호 안 값은 동일 모델·동일 해상도에서 조건 A(real) 대비 조건 B(real+gen)의 각 지표(mAP50, mAP50-95) 증가분(B-A)을 의미한다.

또한 흥미롭게도 입력 해상도와 합성데이터 효과 간 상호작용이 관찰되었다(Table 3). 1280px의 고해상도 조건에서는 오히려 실데이터 단독(A)이 혼합(B)보다 우수하여, 960px에서 나타난 개선 효과가 역전되었다. 이는 고해상도에서 세밀한 실제 텍스처가 중요해질수록 합성-실 도메인 격차(domain gap)가 부각되어, 합성데이터가 실데이터의 디테일을 희석할 수 있음을 시사한다. 한편 평가 시 TTA(다중 스케일·반전 앙상블)를 적용하면 재학습 없이 정확도가 크게 향상되며, 최고 성능은 YOLO11l·실데이터 단독·1280px 학습 + TTA에서 mAP50-95 0.5218(mAP50 0.743)로 측정되었다.

Table 3. 1280px 검출 성능 (YOLO11l, 실-평가셋)

모델	조건	mAP50	mAP50-95
YOLO11l	A: real	0.6412	0.4397
YOLO11l	B: real+gen	0.6376 (-0.0036)	0.4244 (-0.0153)

괄호 안 값은 동일 모델·동일 해상도에서 조건 A(real) 대비 조건 B(real+gen)의 각 지표(mAP50, mAP50-95) 증가분(B-A)이며, 음수는 고해상도에서 합성데이터 혼합 시 성능이 하락(역전)함을 나타낸다

추가로 추론 시 TTA를 적용한 효과를 Table 4에 정리하였다. TTA는 재학습 없이 평가만으로 성능을 향상시키며, YOLO11l·실데이터 단독·1280px + TTA에서 최고 mAP50-95 0.5218을 달성하였다.

Table 4. TTA 적용에 따른 성능 향상 (YOLO11l, 1280px, 실-평가셋, mAP50-95)

조건	Base	+TTA	향상
A: real	0.4397	0.5218	+0.082
B: real+gen	0.4244	0.4772	+0.053

"향상"은 동일 모델·조건에서 base 대비 +TTA의 mAP50-95 증가분이다.

종합하면, (1) 표준 해상도에서 생성형 AI 합성데이터는 검출 성능을 개선하며 대형 모델일수록 효과가 크고, (2) TTA는 재학습 없이 +2~6%p의 향상을 제공하며, (3) 합성데이터의 이득은 입력 해상도에 의존적이다.



Fig. 3. 생성 AI를 입력으로 한 객체 검출 결과 이미지




Fig. 4. 모델 규모에 따른 검출 성능 개선 비교

Fig. 4.는 모델 규모에 따른 검출 성능 개선 비교를 나타낸다. 모든 모델의 경우 real 데이터를 활용했을 때보다(A) 생성형 데이터를 활용했을 때(B) 성능이 개선되었다는 것을 확인할 수 있었다. 동일 데이터 조건에서 YOLO11l(25M)이 YOLO11x(57M)보다 모든 조건에서 높은 mAP50-95를 기록하였다(A: 0.4455 vs 0.4035, B: 0.4581 vs 0.4404). 이는 제한된 학습 데이터 규모에서 모델 파라미터 증가가 성능 향상으로 이어지지 않음을 확인할 수 있다.

IV. Conclusions

본 논문은 생성형 AI로 생성하고 멀티모달 LLM으로 자동 라벨링한 합성 주행 영상을 실데이터에 보강하여 보행자 검출 성능을 개선하는 방안을 제안하였다. 실데이터 37클립과 합성 100클립(30,100프레임)을 구축하고 YOLO11l/11x로 검증한 결과, 표준 해상도(960px)에서 합성데이터 보강이 두 모델 모두의 mAP50-95를 개선함(11l +1.3%p, 11x +3.7%p) 확인하였다. 또한 합성데이터 효과가 입력 해상도에 의존적임을 밝혀, 고해상도 학습 시에는 실·합성 도메인 격차를 고려해야 함을 보였다. 향후 연구로는 실데이터 추가 확보와 사람 검출 평가셋 구축을 통한 절대 성능 향상, 그리고 도메인 격차 완화를 위한 합성-실 정렬(domain alignment) 기법 적용을 계획한다.

ACKNOWLEDGEMENT

본 논문은 한국전자기술연구원(KETI)의 기본연구사업으로 수행된 연구결과물입니다.

REFERENCES

- [1] OpenAI, "Video Generation Models as World Simulators (Sora)," Technical Report, 2024.
- [2] J. Tremblay et al., "Training Deep Networks with Synthetic

- Data: Bridging the Reality Gap by Domain Randomization,"
in Proc. IEEE CVPR Workshops, pp. 969-977, 2018.
- [3] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You
Only Look Once: Unified, Real-Time Object Detection,"
in Proc. IEEE Conf. Computer Vision and Pattern
Recognition (CVPR), pp. 779-788, 2016.
- [4] G. Jocher and J. Qiu, "Ultralytics YOLO11," 2024. [Online].
Available: <https://github.com/ultralytics/ultralytics>
- [5] Gemini Team, Google, "Gemini: A Family of Highly
Capable Multimodal Models," arXiv:2312.11805, 2023.